기업 RAG 도입 핵심 정리

RAG는 AI가 답하기 전에 회사 문서를 먼저 찾아 읽게 하는 방식입니다. 도입의 성패는 모델 선택보다 **어떤 질문에, 어떤 문서로, 누구에게 답할지**를 정하는 준비에서 갈립니다.

1. 담당자가 먼저 준비할 것

1. **목표와 사용자 정하기**: 풀 문제, 주 사용자, 성공 지표(응답 시간, 정확도, 문의 감소율)를 한 문장으로 정리
2. **보안 검토와 범위 확정**: 개인정보·급여 같은 제한 문서 분류, 외부 모델 사용 가능 여부 합의
3. **평가 질문 세트 작성**: 질문 30개 이상, 근거 문서와 기대 답변, **답하면 안 되는 질문**까지 포함 (업로드 전에 미리 준비)
4. **문서 정리**: 구버전·중복 제거, 문서군별 폴더 생성, 파일명 규칙 적용, 조항 구조 정리
5. **업로드**: 서비스가 자동으로 청킹해서 벡터DB에 저장
6. **챗봇 테스트**: 평가 질문으로 검증
7. **원인별 수정 후 재테스트**
8. **운영**: 문서 갱신 담당자 지정, 로그 점검

2. 문서 준비 규칙

- 폴더 예시: `인사규정_v2025.03`
- 파일명 예시: `휴가관련조항_20250602개정_적용(정규직)_소유(인사).pdf`
- 파일 내부는 "제5조(연차휴가)"처럼 조항 제목이 명확하게 구분되도록 작성
- 글자를 읽을 수 있는 PDF 사용 (스캔 이미지는 OCR 필요)
- 개정일·적용 대상·소유 부서는 파일명뿐 아니라 문서 내용이나 서비스 메타데이터에도 가능하면 입력
- **청킹은 사람이 직접 하지 않습니다.** 업로드하면 서비스가 자동으로 나누므로, 담당자는 자동 분할이 잘 되도록 문서 구조를 정리합니다.

3. 챗봇 지침과 제한 정보 처리

- 대부분의 RAG 서비스에는 챗봇 지침(시스템 프롬프트) 입력·수정 기능이 있을 가능성이 높습니다. 길이 제한, 수정 권한, 문서군별 지침 가능 여부는 서비스에 확인이 필요합니다.
- 지침 예시: 근거 문서 내용만 답하기, 출처(문서·조항) 표시, 근거가 없으면 "확인되지 않습니다"라고 답하기, 급여 등 제한 정보는 담당 부서 안내
- "답하면 안 되는 질문"은 업로드 파일이 아니라 **평가 질문 세트와 챗봇 지침**에서 다룹니다.
- 지침은 100% 차단을 보장하지 않으므로, **민감 문서는 아예 업로드하지 않거나 권한으로 분리**하는 것이 가장 안전합니다.

4. 오답이 나왔을 때: 원인부터 분류

원인	증상	조치
문서 문제	구버전 혼재, 내용 누락, 표가 잘림	문서 수정·교체 후 재업로드
검색·분할 문제	엉뚱한 조항을 찾아옴	서비스의 분할·검색 설정 조정
답변 방식 문제	근거 없이 지어냄, 거절 못 함	챗봇 지침 수정

규정 자체의 문제	규정이 모호하거나 서로 충돌	해당 부서와 규정 정비 협의

수정할 때마다 **같은 평가 세트로 재테스트**합니다. 하나를 고치다 다른 답이 나빠질 수 있기 때문입니다.

5. 가장 시간이 오래 걸리는 단계: 문서 준비

시간이 드는 작업은 파일명 붙이기보다 아래 항목입니다.

- 구버전·중복 문서 가려내기
- 보안 검토와 제한 정보 분류 (여러 부서 협의 필요)
- 스캔본 OCR 변환
- 조항 구조 정리
- 규정 간 충돌 확인

시간을 줄이는 방법: 한두 문서군으로 먼저 시작해 정리 규칙 만들기, 파일명 규칙 단순화와 템플릿화, 문서 소유 부서가 직접 정리하도록 역할 분담, 반복 작업은 일괄 처리 도구 활용

6. 예제 시나리오 (가상): 한빛전자 사내 규정 도우미

- 회사: 직원 1,200명 제조업, 인사·IT·품질 규정 문의가 하루 약 80건
- 목표: 6개월 내 반복 문의 40% 감소, 답변에 근거 조항 표시
- 1차 범위: 인사 규정 + IT 가이드
- PoC 1차 결과: 검색 정확도 78%(기준 90%), 거절 정확도 70%(기준 95%)
- 개선: 청크를 조항 단위로 재분할, 구버전 제거, "근거 없으면 모른다고 답하라" 지침 강화 후 재측정

7. 서비스 화면 시안 (직접 설계)

관리자 콘솔을 5개 화면으로 구성했습니다.

1. **문서 관리**: 폴더별 파일, 메타데이터, 처리 상태
2. **청킹 확인**: 조항 단위 분할 결과, 문제 조각 표시
3. **챗봇 지침**: 지침 입력, 옵션, 버전 이력
4. **평가 테스트**: 질문 세트 일괄 실행, 통과·실패 확인
5. **운영 로그**: 질문·실패 현황, 실패 질문을 평가 세트에 추가

설계 핵심: 업로드 단계에서 문제를 미리 잡고, 수정 후 같은 평가 세트로 반복 검증하며, 운영 중 실패한 질문을 평가 세트로 되돌리는 **순환 구조**입니다.

8. 솔브레인 담당자에게 확인할 항목

- 지원 파일 형식, 스캔본 OCR 지원 여부
- 자동 청킹 방식, 설정 가능 범위, 청킹 결과 확인 기능
- 메타데이터 입력과 폴더(문서군)별 권한 관리
- 챗봇 지침의 길이 제한·수정 권한·버전 관리
- 답변의 출처 표시, 로그·피드백 기능
- 외부 모델 사용 여부와 데이터 보관 위치
- 관리자 화면 시연(데모)이나 체험 계정 제공 여부

> 솔브레인 서비스의 실제 기능과 화면은 공개 자료에서 확인하지 못했으며, 이 문서의 서비스 관련 내용은 일반적인 RAG 서비스를 기준으로 한 것입니다. 예제 회사와 수치는 설명을 위한 가상 데이터입니다.

> 실현적인 RAG 서비스를 기준으로 한 것입니다. 예제 회사와 주식은 설명을 위한 가상 데이터입니다.